


Local Linear Embedding

Methods

❖ Local Linear Embedding (LLE)

- LLE는 eigenvector를 활용하는 비선형 차원 축소 기법 중 하나
- 고차원의 공간에서 인접해 있는 데이터들 사이의 선형적 구조를 보존하면서 저차원으로 임베딩하는 방법론
- Closed-form solution이 존재하기 때문에 적용이 간단하며, local minima 문제에서 자유로움



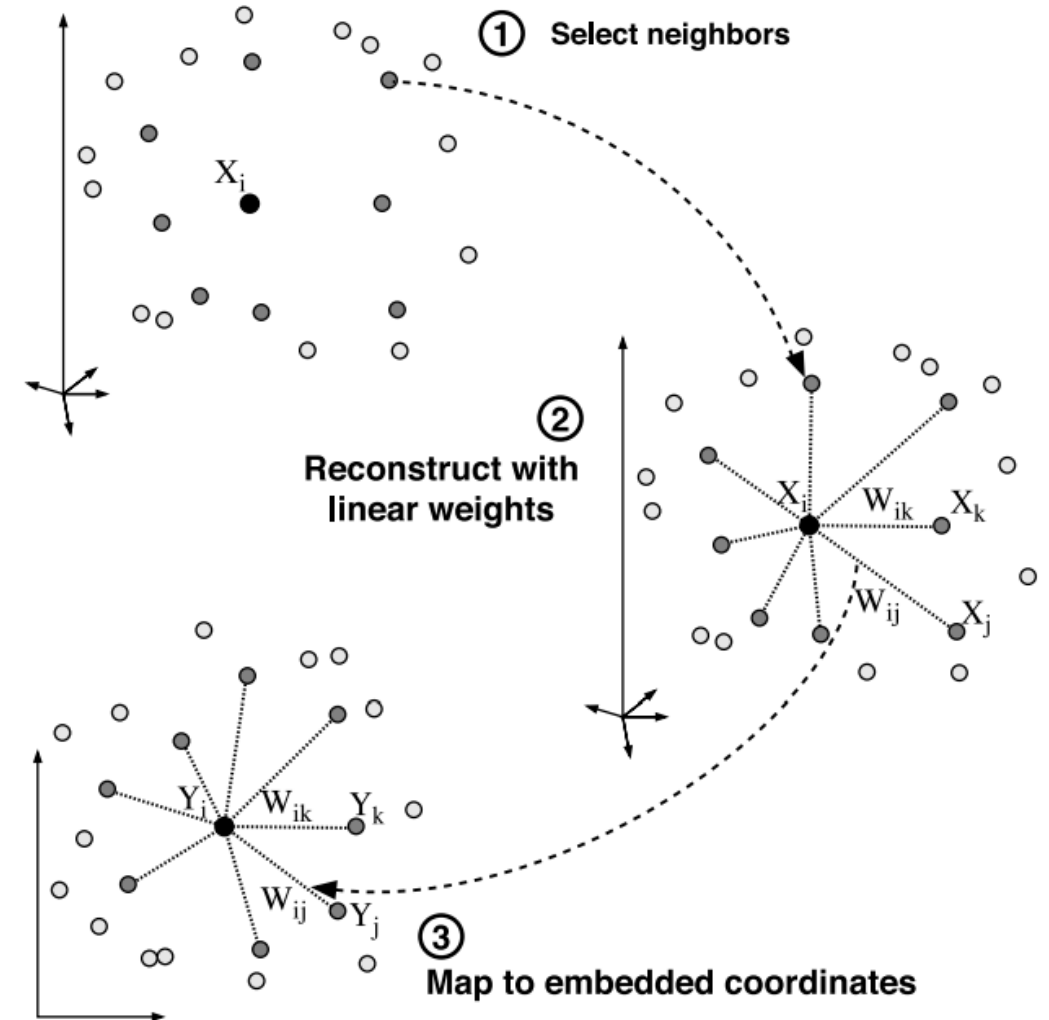
Local Linear Embedding

Methods

❖ LLE algorithm

- LLE는 총 3개의 단계로 구성되어 있음

1. i 번째 관측치인 x_i 의 이웃 관측치를 선택
2. 모든 관측치에 대해 x_i 를 이웃 관측치의 선형 결합으로 가장 잘 설명할 수 있는 w_{ij} 탐색
3. 선형 관계를 유지하며 저차원으로 매핑되는 좌표 y_i 탐색





Local Linear Embedding

Methods

❖ LLE algorithm

1. i 번째 관측치인 $x_i \in R^d$ 의 이웃 관측치를 선택

→ 이 때, 몇 개의 nearest neighbors를 사용할지는(a.k.a. k) 사용자가 정하는 hyperparameter



Reconstruction

Error

Trade-off

Locality

Local Linear Embedding


Methods

❖ LLE algorithm

2. 모든 관측치에 대해 x_i 를 이웃 관측치의 선형 결합으로 가장 잘 설명할 수 있는 W_{ij} 탐색

→ 모든 관측치마다 W_{ij} 를 계산 ($W \in R^{N \times N}$)

→ convex function이기 때문에 closed-form solution 존재



$$\text{minimize } E(W) = \sum_{i=1}^N \left| x_i - \sum_{j=1}^k W_{ij} x_j \right|^2$$

s. t. $W_{ij} = 0$, if x_j does not belong to the neighbor of x_i

$$\sum_{j=1}^k W_{ij} = 1 \text{ for all } i$$


Local Linear Embedding

Methods

❖ LLE algorithm

3. 선형 관계를 유지하며 저차원으로 매핑되는 좌표 $y_i \in R^{d'}$ 탐색

→ 고차원에서의 선형결합을 가장 잘 보존할 수 있는 y_i 를 찾는 것이 목적



$$\min_{\mathbf{y}} \Phi(\mathbf{W}) = \sum_i \left| \mathbf{y}_i - \sum_j \mathbf{W}_{ij} \mathbf{y}_j \right|^2 \Rightarrow \Phi(\mathbf{W}) = \sum_{i,j} \mathbf{M}_{ij} (\mathbf{y}_i \cdot \mathbf{y}_j)$$

where $\mathbf{M}_{ij} = \delta_{ij} - \mathbf{W}_{ij} - \mathbf{W}_{ji} + \sum_k \mathbf{W}_{ki} \mathbf{W}_{kj}$, $\delta_{ij} = 1$ if $i = j$, 0 otherwise

$$s.t. \sum_i \mathbf{y}_i = 0, \frac{1}{n} \sum_i \mathbf{y}_i \mathbf{y}_i^T = \mathbf{I}$$

Local Linear Embedding

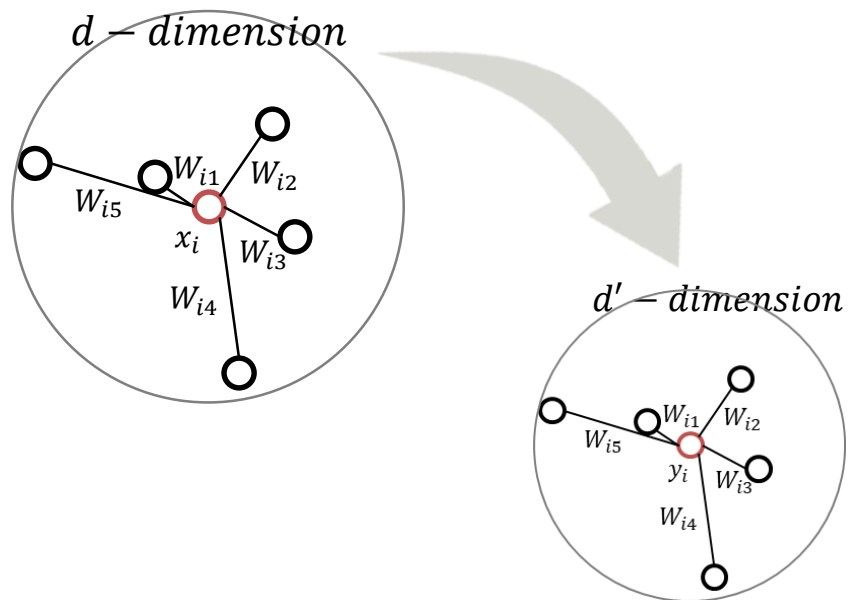
Methods

❖ LLE algorithm

3. 선형 관계를 유지하며 저차원으로 매핑되는 좌표 $y_i \in R^{d'}$ 탐색

→ 고차원에서의 선형결합을 가장 잘 보존할 수 있는 y_i 를 찾는 것이 목적

→ Rayleitz-Ritz theorem에 의해서 y 의 closed-form solution이 M 행렬의 가장 작은 d개의 eigenvectors가 됨



$$\begin{aligned}\min_{\mathbf{y}} \Phi(\mathbf{W}) &= \sum_i \left| \mathbf{y}_i - \sum_j \mathbf{w}_{ij} \mathbf{y}_j \right|^2 \\ &= \left[(\mathbf{I} - \mathbf{W}) \mathbf{y} \right]^T (\mathbf{I} - \mathbf{W}) \mathbf{y} \\ &= \mathbf{y}^T (\mathbf{I} - \mathbf{W})^T (\mathbf{I} - \mathbf{W}) \mathbf{y} \\ &= \mathbf{y}^T \mathbf{M} \mathbf{y}\end{aligned}$$

Local Linear Embedding

Methods

❖ Dimensionality Reduction using LLE

