Chapter 2. Kernel-based Learning

고려대학교 산업경영공학과

DMQA Lab.

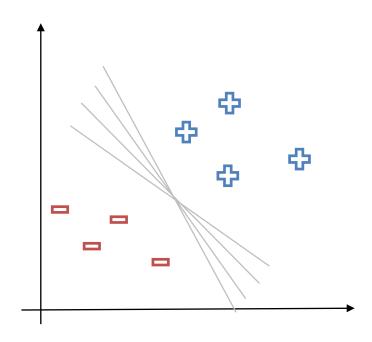
임새린





Methods

- Support Vector Machine
 - 기계학습 알고리즘 중 하나로 탄탄한 이론적 배경, 손쉬운 적용, 그리고 준수한 성능을 가지고 있음
 - '이진 분류 문제에서 어떤 decision boundary가 가장 좋은 decision boundary인가?'에 대한 하나의 답을 알고리즘으로 개발

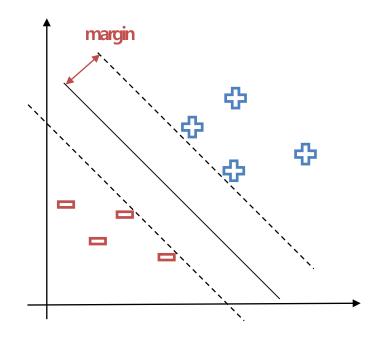


What is the best decision boundary?

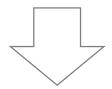


Methods

- Support Vector Machine
 - 기계학습 알고리즘 중 하나로 탄탄한 이론적 배경, 손쉬운 적용, 그리고 준수한 성능을 가지고 있음
 - '이진 분류 문제에서 어떤 decision boundary가 가장 좋은 decision boundary인가?'에 대한 하나의 답을 알고리즘으로 개발



What is the best decision boundary?



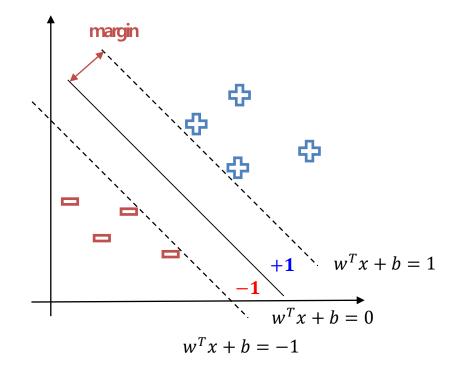
The decision boundary that maximize the margin

*Margin이란 분류 경계면으로부터 가장 가까운 양쪽 범주 객체와의 거리

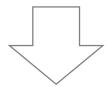


Methods

- Support Vector Machine
 - 기계학습 알고리즘 중 하나로 탄탄한 이론적 배경, 손쉬운 적용, 그리고 준수한 성능을 가지고 있음
 - '이진 분류 문제에서 어떤 decision boundary가 가장 좋은 decision boundary인가?'에 대한 하나의 답을 알고리즘으로 개발



What is the best decision boundary?



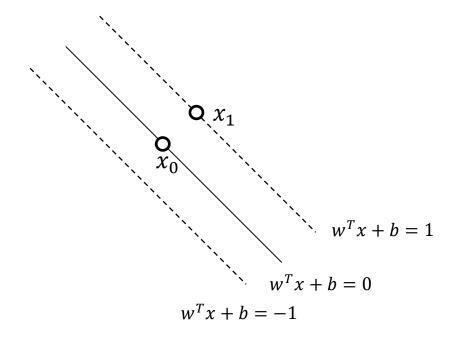
The decision boundary that maximize the margin

*Margin이란 분류 경계면으로부터 가장 가까운 양쪽 범주 객체와의 거리

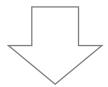


Methods

- How to get the margin?
 - Hyperplane의 법선 벡터 w를 활용하면 쉽게 유도 가능

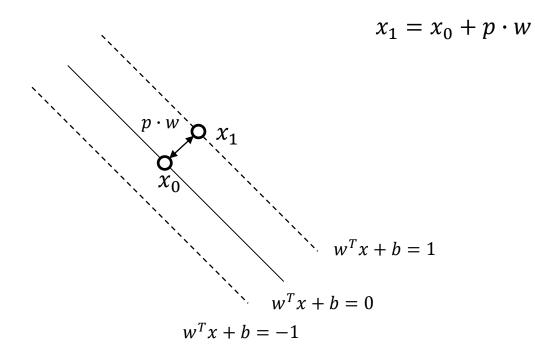


How to get the margin?

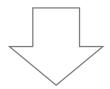


Methods

- How to get the margin?
 - Hyperplane의 법선 벡터 w를 활용하면 쉽게 유도 가능

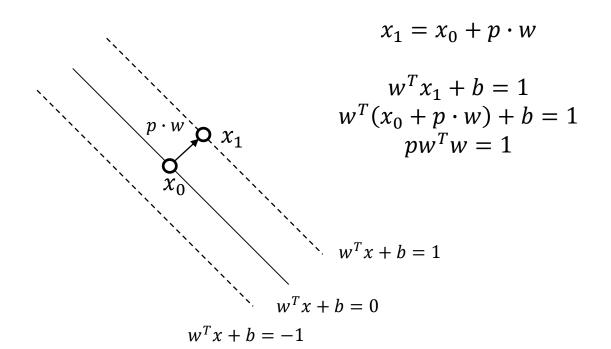


How to get the margin?

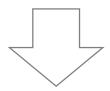


Methods

- How to get the margin?
 - Hyperplane의 법선 벡터 w를 활용하면 쉽게 유도 가능

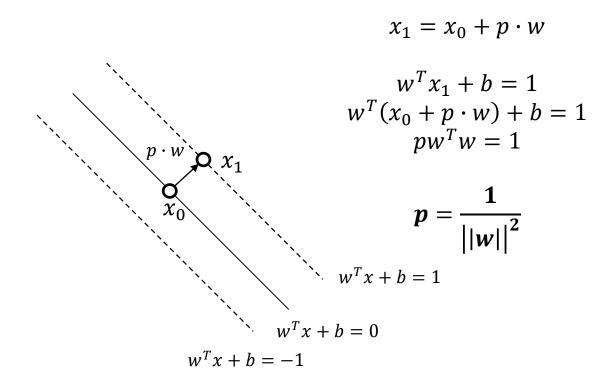


How to get the margin?

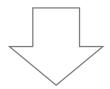


Methods

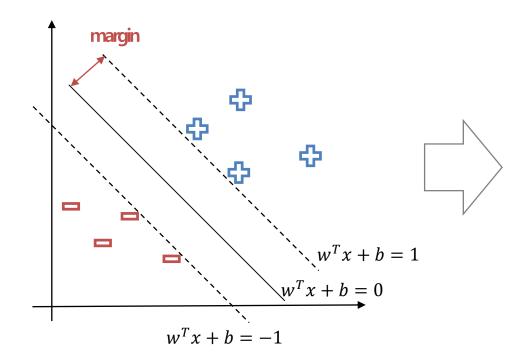
- How to get the margin?
 - Hyperplane의 법선 벡터 w를 활용하면 쉽게 유도 가능



How to get the margin?



- Maximize margin
 - 최종적으로 다음과 같은 최적화 문제를 푸는 것이 목표



$$\max \frac{1}{\left|\left|w\right|\right|^{2}} \leftrightarrow \min \frac{1}{2}\left|\left|w\right|\right|^{2}$$

s.t.
$$y_i(w^Tx_i + b) \ge 1$$
, for all i

$$y_i = \begin{cases} 1 & if w^T x_i + b \ge 1 \\ -1 & o.w. \end{cases}$$

Methods

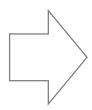
- Primal problem to Dual problem using Lagrange multiplier
 - 문제를 쉽게 해결하기 위해 Lagrange multiplier를 활용해 Dual problem으로 변경

Primal Problem

$$\min L_p(w) = \frac{1}{2} ||w||^2$$

s.t. $y_i(w^Tx_i + b) \ge 1$, for all i

Lagrangian Problem



$$\min L_p(w, b, \alpha_i) = \frac{1}{2} ||w||^2 - \sum_{i=1}^N \alpha_i (y_i(w^T x_i + b) - 1)$$

s.t.
$$\alpha_i \geq 0$$
, for all i

KKT condition

•
$$\frac{\partial L_p}{\partial w} = 0 \rightarrow w = \sum_{i=1}^N \alpha_i y_i x_i$$
 • $\frac{\partial L_p}{\partial b} = 0 \rightarrow \sum_{i=1}^N \alpha_i y_i = 0$



Methods

- Primal problem to Dual problem using Lagrange multiplier
 - 문제를 쉽게 해결하기 위해 Lagrange multiplier를 활용해 Dual problem으로 변경
 - α_i 에 대한 convex 함수이기 때문에 쉽게 최적해를 찾을 수 있음

Lagrangian Problem

min
$$L_p(w, b, \alpha_i) = \frac{1}{2} ||w||^2 - \sum_{i=1}^N \alpha_i (y_i(w^T x_i + b) - 1)$$

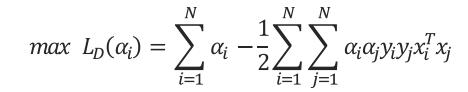
s.t. $\alpha_i \geq 0$, for all i

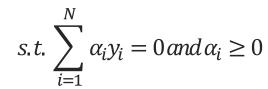
KKT condition

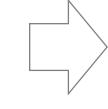
•
$$\frac{\partial L_p}{\partial w} = 0 \rightarrow w = \sum_{i=1}^N \alpha_i y_i x_i$$
 • $\frac{\partial L_p}{\partial h} = 0 \rightarrow \sum_{i=1}^N \alpha_i y_i = 0$

$$\frac{\partial L_p}{\partial h} = 0 \rightarrow \sum_{i=1}^N \alpha_i y_i = 0$$

Dual Problem









Methods

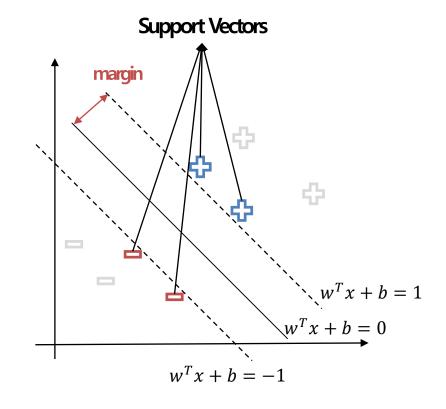
- Support Vector
 - KKT condition을 통해서 margin 위에 있는 관측치(support vector)만 있으면 문제를 해결이 가능함을 알 수 있음

KKT condition

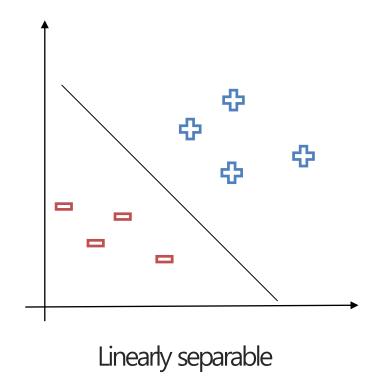
$$\alpha_i(y_i(w^Tx_i + b) - 1) = 0 \to \begin{cases} \alpha_i = 0 & \leftrightarrow y_i(w^Tx_i + b) - 1 \neq 0 \\ \alpha_i \neq 0 & \leftrightarrow y_i(w^Tx_i + b) - 1 = 0 \end{cases}$$

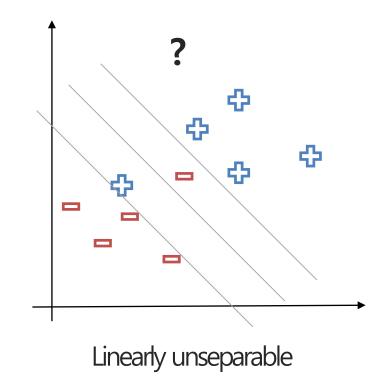


$$w = \sum_{i=1}^{N} \alpha_i y_i x_i = \sum_{i \in SV}^{N} \alpha_i y_i x_i$$

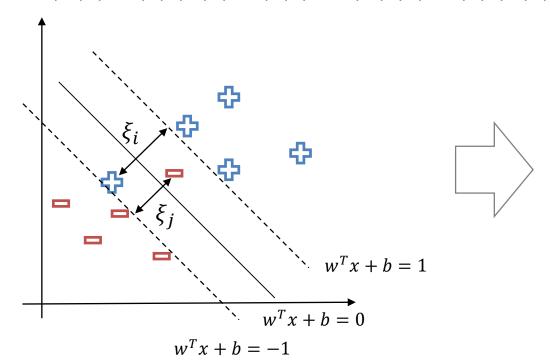


- Soft Margin SVM
 - SVM은 데이터가 선형적으로 분리가 가능한 상황을 가정
 - 하지만 현실에서 선형 분리가 가능한 데이터는 거의 존재하지 않음





- Soft Margin SVM
 - 패널티 개념을 도입하여 문제 해결
 - 적절히 에러를 허용하며 margin을 최대화
 - C가 커지면 에러에 대해 엄격해지고 C가 작아지면 에러에 대해 관대



min
$$L_p(w) = \frac{1}{2} ||w||^2 + C \sum_{i=1}^{N} \xi_i$$

s.t.
$$y_i(w^Tx_i + b) \ge 1 - \xi_i$$
, $\xi_i \ge 0$ for all i

Methods

- Soft Margin SVM
 - Lagrangian problem으로 변환

Primal Problem

$$L_p(w) = \frac{1}{2} ||w||^2 + C \sum_{i=1}^{N} \xi_i$$

s.t. $y_i(w^Tx_i + b) \ge 1 - \xi_i$, $\xi_i \ge 0$ for all i

Lagrangian Problem

$$L_{p}(w,b,\alpha_{i}) = \frac{1}{2}||w||^{2} + C\sum_{i=1}^{N} \xi_{i} - \sum_{i=1}^{N} \alpha_{i}(y_{i}(w^{T}x_{i} + b) - 1 + \xi_{i}) - \sum_{i=1}^{N} \mu_{i}\xi_{i}$$

$$s.t. \ \alpha_{i} \geq 0, \ \mu_{i} \geq 0 \ for \ all \ i$$

KKT condition

•
$$\frac{\partial L_p}{\partial w} = 0 \rightarrow w = \sum_{i=1}^N \alpha_i y_i x_i$$
 • $\frac{\partial L_p}{\partial b} = 0 \rightarrow \sum_{i=1}^N \alpha_i y_i = 0$ • $\frac{\partial L_p}{\partial \xi_i} = 0 \rightarrow C - \alpha_i - \mu_i = 0$



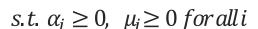
Methods

- Soft Margin SVM
 - KKT condition을 이용해 Dual problem으로 변환
 - Dual problem은 convex 함수이기 때문에 쉽게 최적해를 찾을 수 있음

Lagrangian Problem

$$L_{p}(w,b,\alpha_{i}) = \frac{1}{2} ||w||^{2} + C \sum_{i=1}^{N} \xi_{i}$$

$$-\sum_{i=1}^{N} \alpha_{i} (y_{i}(w^{T}x_{i} + b) - 1 + \xi_{i}) - \sum_{i=1}^{N} \mu_{i} \xi_{i}$$



Dual Problem

$$\max L_{D}(\alpha_{i}) = \sum_{i=1}^{N} \alpha_{i} - \frac{1}{2} \sum_{i=1}^{N} \sum_{j=1}^{N} \alpha_{i} \alpha_{j} y_{i} y_{j} x_{i}^{T} x_{j}$$

s.t.
$$\sum_{i=1}^{N} \alpha_i y_i = 0 \text{ and } 0 \le \alpha_i \le C$$



Methods

- Soft Margin SVM
 - KKT condition을 이용해 Dual problem으로 변환
 - Dual problem은 convex 함수이기 때문에 쉽게 최적해를 찾을 수 있음

KKT condition

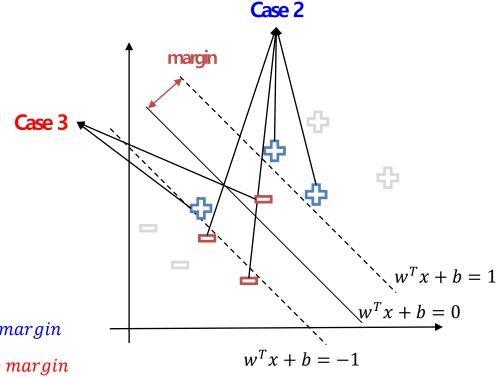
$$\alpha_i(y_i(w^Tx_i+b)-1+\xi_i)=0$$

$$C - \alpha_i - \mu_i = 0 \quad \& \quad \mu_i \xi_i = 0$$

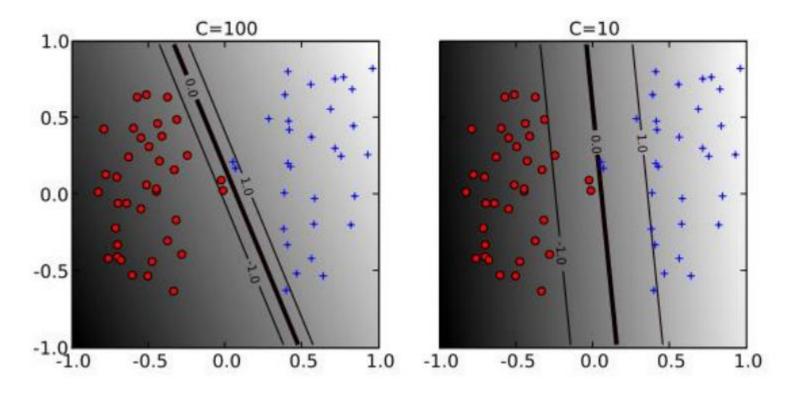


$$w = \sum_{i=1}^{N} \alpha_i y_i x_i = \sum_{i \in SV}^{N} \alpha_i y_i x_i$$

- case 1: $\alpha_i = 0 \rightarrow non support vectors$
- case 2: $0 < \alpha_i < C \rightarrow support\ vectors\ on\ the\ margin$
- case 3: $\alpha_i = C \rightarrow support\ vectors\ outside\ the\ margin$

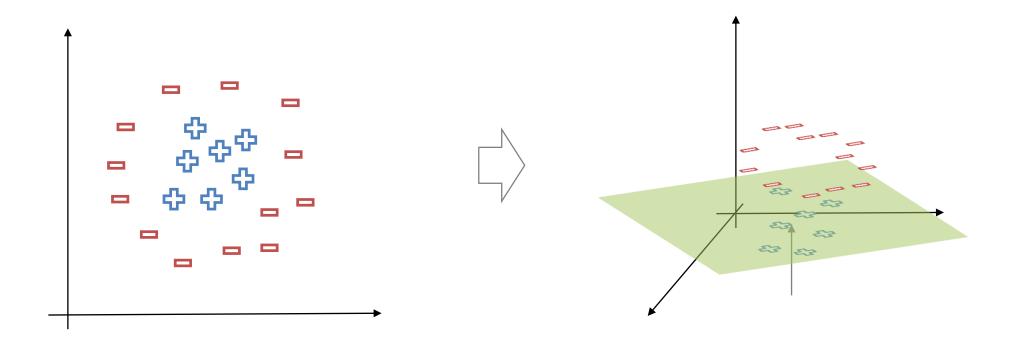


- Soft Margin SVM
 - C가 크면 패널티를 거의 허용하지 않음 → margin이 줄어듦
 - C가 작으면 패널티를 많이 허용 → margin이 넓어짐





- Non-linear decision boundary
 - SVM은 기본적으로 선형 분류 경계선을 가정하기 때문에 non-linear한 상황에서는 좋은 성능을 낼 수 없음
 - 고차원으로 매핑하는 함수 $\Phi(x)$ 를 통해 관측치를 고차원으로 매핑하여 선형 분류





Methods

- Non-linear decision boundary
 - SMM은 기본적으로 선형 분류 경계선을 가정하기 때문에 non-linear한 상황에서는 좋은 성능을 낼 수 없음
 - 고차원으로 매핑하는 함수 $\Phi(x)$ 를 통해 관측치를 고차원으로 매핑하여 선형 분류

Primal Problem

Lagrangian Problem

$$L_{p}(w) = \frac{1}{2}||w||^{2} + C\sum_{i=1}^{N} \xi_{i}$$

$$L_{p}(w,b,\alpha_{i}) = \frac{1}{2}||w||^{2} + C\sum_{i=1}^{N} \xi_{i} - \sum_{i=1}^{N} \alpha_{i}(y_{i}(w^{T}\Phi(x_{i}) + b) - 1 + \xi_{i}) - \sum_{i=1}^{N} \mu_{i}\xi_{i}$$

$$s.t. \ y_{i}(w^{T}\Phi(x_{i}) + b) \ge 1 - \xi_{i}, \ \xi_{i} \ge 0 \quad for all \ i$$

$$s.t. \ \alpha_{i} \ge 0, \ \mu_{i} \ge 0 \ for all \ i$$

KKT condition

•
$$\frac{\partial L_p}{\partial w} = 0 \rightarrow w = \sum_{i=1}^N \alpha_i y_i \Phi(x_i)$$
 • $\frac{\partial L_p}{\partial b} = 0 \rightarrow \sum_{i=1}^N \alpha_i y_i = 0$ • $\frac{\partial L_p}{\partial \xi_i} = 0 \rightarrow C - \alpha_i - \mu_i = 0$

Methods

- Non-linear decision boundary
 - SMM은 기본적으로 선형 분류 경계선을 가정하기 때문에 non-linear한 상황에서는 좋은 성능을 낼 수 없음
 - 고차원으로 매핑하는 함수 $\Phi(x)$ 를 통해 관측치를 고차원으로 매핑하여 선형 분류

Lagrangian Problem

$L_{p}(w,b,\alpha_{i}) = \frac{1}{2} ||w||^{2} + C \sum_{i=1}^{N} \xi_{i}$ $-\sum_{i=1}^{N} \alpha_{i} (y_{i}(w^{T} \Phi(x_{i}) + b) - 1 + \xi_{i}) - \sum_{i=1}^{N} \mu_{i} \xi_{i}$

s.t. $\alpha_i \ge 0$, $\mu_i \ge 0$ for all i

Dual Problem

$$\max L_D(\alpha_i) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \Phi(x_i)^T \Phi(x_i)$$

s.t.
$$\sum_{i=1}^{N} \alpha_i y_i = 0 \text{ and } 0 \le \alpha_i \le C$$



Methods

- * Kernel trick for non-linear decision boundary
 - 최적해를 찾기 위해서 우리가 필요한 값은 $\Phi(x_i)$ 가 아닌 $\Phi(x_i)^T\Phi(x_i)$
 - Kernel function을 통해 더 효율적이며 현재까지 알려진 다양한 kernel function을 활용해 더 유연하게 문제 해결 가능

Dual Problem

$$\max L_D(\alpha_i) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \Phi(x_i)^T \Phi(x_j)$$

s.t.
$$\sum_{i=1}^{N} \alpha_i y_i = 0 \text{ and } 0 \le \alpha_i \le C$$

$$x_{i} \longrightarrow \Phi(x_{i}) \longrightarrow \Phi(x_{i})^{T} \Phi(x_{j})$$

$$x_{j} \longrightarrow \Phi(x_{j})$$

Kernel Trick
$$x_i \longrightarrow \Phi(x_i)^T \Phi(x_j)$$

$$K(x_i, x_j)$$

Methods

- Kernel functions
 - Polynomial kernel, Sigmoid kernel, Gaussian (RBF) kernel 등 많은 kernel 함수가 알려져 있음
 - 그 중 차원을 무한으로 확장할 수 있는 Gaussian kernel을 가장 많이 활용

$$K(x,y) = \exp\left(-\frac{||x-y||^2}{2\sigma^2}\right), \quad \sigma \neq 0$$

Gaussian kemel

$$K(x,y) = (x \cdot y + c)^d, \quad c > 0$$

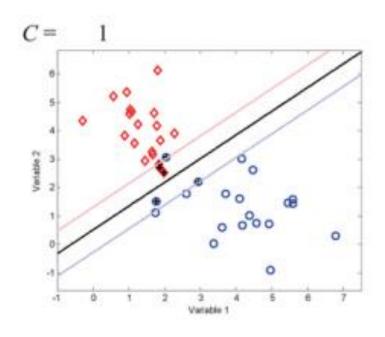
$$K(x,y) = \tanh(a(x \cdot y) + b), \quad a, b \ge 0$$

Sigmoid kemel

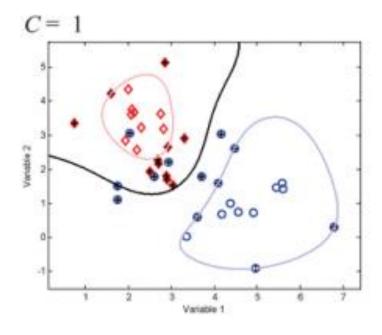
Polynomial kemel



- Kernel functions
 - Polynomial kernel, Sigmoid kernel, Gaussian (RBF) kernel 등 많은 kernel 함수가 알려져 있음
 - 그 중 Gaussian kernel을 가장 많이 활용



Linear kemel



Gaussian kernel



감사합니다

